UNIVERSIDAD AUTÓNOMA DE OCCIDENTE

Proyecto Final – Curso ETL y Ciencia de Datos – Entrega Final

Profesor: Fernando Barraza A
Periodo académico: 2026

Estudiantes:

- Melissa Palacios
- Diego Valencia
- Waldor Drada
- Jorge Andrés Rivas

1. Introducción

La contaminación del aire es un problema ambiental y de salud pública a nivel mundial, asociado con enfermedades respiratorias y cardiovasculares. En Colombia, representa un reto importante en ciudades altamente pobladas e industrializadas. Aunque existen datos abiertos y sistemas de monitoreo, la información se encuentra dispersa y en distintos formatos, lo que dificulta su integración y análisis.

El objetivo de este proyecto es construir un proceso ETL (Extract, Transform, Load) que permita integrar datos de calidad del aire de Colombia y datos globales, con el fin de generar un dataset limpio y estructurado que facilite el análisis comparativo y la generación de conocimiento a partir de los datos.

En los proyectos de ciencia de datos, el proceso ETL es una etapa fundamental, ya que la calidad de los análisis y modelos depende directamente de la calidad, consistencia e integración de los datos. Por esta razón, el diseño de pipelines ETL reproducibles y estructurados es una práctica clave en la ingeniería de datos y en proyectos de analítica avanzada.

2. Definición del problema

El problema central del proyecto es la falta de estandarización e integración de múltiples fuentes de datos de calidad del aire, lo cual dificulta la realización de análisis comparativos entre Colombia y otros países. Los datos se encuentran en diferentes formatos, con diferentes nombres de variables y estructuras, lo que impide su uso directo para análisis de ciencia de datos.

La pregunta principal que orienta el proyecto es: **¿Cómo integrar y estandarizar datos de calidad del aire de Colombia y del contexto global para permitir análisis comparativos y estudios posteriores de ciencia de datos?**

3. Fuentes de datos

Para el desarrollo del proyecto se utilizaron dos fuentes de datos abiertas:

3.1. Calidad del Aire en Colombia – Datos Abiertos

Fuente oficial del gobierno colombiano que contiene información de estaciones de monitoreo de calidad del aire en diferentes ciudades del país.

Variables principales:

- Año
- Nombre del municipio
- Contaminante (PM2.5, PM10, NO2, SO2, O3, CO)
- Promedio anual
- Unidad de medida

Este dataset contiene miles de registros históricos organizados por ciudad, contaminante y año.

3.2. Global Air Pollution Data – Kaggle

Dataset público que contiene información de calidad del aire a nivel mundial.

Variables principales:

- País
- Ciudad
- AQI (Air Quality Index)
- PM2.5
- NO2
- O3
- CO

La selección de estas fuentes de datos permite analizar la calidad del aire en Colombia dentro de un contexto global, lo cual facilita la comparación entre ciudades y países, y permite identificar patrones de contaminación a nivel internacional. La integración de estas fuentes genera mayor valor analítico que el uso de cada dataset por separado.

4. Exploración inicial de datos

4.1 Primera etapa de verificación

En esta etapa se realizó un análisis exploratorio inicial para conocer la estructura de los datos, tipos de variables, valores nulos y posibles problemas de calidad de datos.

En cuanto al dataset de Datos Abiertos Colombia se encontró:

- Aproximadamente 29,000 registros.
- Más de 20 variables relacionadas con mediciones de contaminantes, estaciones, ubicación y estadísticas.
- Algunas variables numéricas se encontraban almacenadas como texto, por lo que fue necesario convertirlas a tipo numérico.
- Se encontraron valores nulos en algunas variables como representatividad temporal y tipo de estación.
- Se encontraron registros duplicados.

Para el dataset global se encontró:

- Más de 23,000 registros.
- Variables relacionadas con país, ciudad, AQI y contaminantes.
- Se encontraron valores nulos en las columnas Country y City, los cuales fueron eliminados para garantizar la integridad del análisis.

Esta etapa permitió identificar problemas de calidad de datos y definir las transformaciones necesarias.

Durante la exploración inicial se revisaron dimensiones, columnas, tipos de datos, valores nulos, duplicados y variables presentes en cada fuente.

4.2 Exploración profunda.

Dataset de Colombia:

- Se identificaron 29,683 registros y 28 columnas.
- Varias variables numéricas estaban almacenadas como texto, por lo que fue necesaria su conversión durante la fase de transformación.
- Se detectaron valores nulos en columnas como Representatividad Temporal, Código del Municipio y Tipo de Estación.
- Se encontraron 13,938 registros duplicados.

Dataset global:

- Se identificaron 23,463 registros y 12 columnas.
- Se detectaron valores nulos principalmente en las columnas Country y City.

```
Columnas:
['ID Estacion', 'Autoridad Ambiental', 'Estación', 'Latitud', 'Longitud', 'Variable', 'Unidades', 'Tiempo de exposición (horas)', 'Año', 'Promedio', 'Suma', 'No. de datos', 'Representatividad Temporal', 'Excedencias limite actual',
 'Porcentaje excedencias limite actual', 'Mediana', 'Percentil 98', 'Máximo', 'Fechas/horas del máximo', 'Mínimo', 'Fechas/horas del mínimo', 'Días de excedencias', 'Código del Departamento', 'Nombre del Departamento', 'Código del
Municipio', 'Nombre del Municipio', 'Tipo de Estación', 'Ubicacion']

Tipos de datos:
ID Estacion                          str
Autoridad Ambiental                  str
Estación                             str
Latitud                          float64
Longitud                         float64
Variable                             str
Unidades                             str
Tiempo de exposición (horas)       int64
Año                                  str
Promedio                             str
Suma                                 str
No. de datos                         str
Representatividad Temporal       float64
Excedencias limite actual          int64
Porcentaje excedencias limite actual  float64
Mediana                              str
Percentil 98                         str
Máximo                               str
Fechas/horas del máximo              str
Mínimo                               str
Fechas/horas del mínimo              str
Días de excedencias                int64
Código del Departamento            int64
Nombre del Departamento              str
Código del Municipio             float64
Nombre del Municipio                 str
Tipo de Estación                     str
Ubicacion                            str
dtype: object

Valores nulos:
ID Estacion                        0
Autoridad Ambiental                0
Estación                           0
Latitud                            0
Longitud                           0
Variable                           0
Unidades                           0
Tiempo de exposición (horas)       0
Año                                0
Promedio                           0
Suma                               0
No. de datos                       0
Representatividad Temporal       148
```

Imagen 1. Evidencia de exploración y calidad inicial de los datasets.

4.1. Problema de calidad de datos

Durante la exploración de los datos se identificaron varios problemas de calidad de datos que debieron ser tratados durante el proceso ETL.
Entre los principales problemas encontrados se encuentran:

- Valores nulos en variables importantes como PM10, SO2 y AQI.
- Variables numéricas almacenadas como texto, especialmente la variable Promedio en el dataset de Colombia.
- Diferencias en los nombres de las columnas entre los datasets (Country / País, City / Ciudad).
- Diferencias en la estructura de los datasets (dataset de Colombia en formato largo y dataset global en formato ancho).
- Presencia de registros duplicados en el dataset de Colombia.

Estos problemas justifican la necesidad de un proceso ETL que permita limpiar, transformar y estandarizar los datos antes de su análisis.

5. Proceso ETL

El proyecto implementó un proceso ETL utilizando Python y la librería pandas. El proceso se dividió en tres etapas:

5.1. Extracción (Extract)

Se cargaron los datasets desde archivos CSV utilizando Python. En esta etapa se verificó que los archivos existieran y se cargaran correctamente en estructuras de datos tipo DataFrame.

5.2. Transformación (Transform)

En esta etapa se realizaron las siguientes transformaciones:

- Filtrado de contaminantes relevantes: PM2.5, PM10, NO2, SO2, O3 y CO.
- Conversión de la columna "Promedio" a tipo numérico.
- Transformación del dataset de Colombia de formato largo a formato ancho utilizando una tabla pivot.
- Renombrado de columnas para estandarizar nombres (por ejemplo, Country a País, City a Ciudad).
- Eliminación de valores nulos en variables críticas como país y ciudad.
- Selección de variables relevantes para el análisis.
- Estandarización de la estructura de ambos datasets para permitir su integración.

El dataset de Colombia se encontraba en formato largo, donde cada fila representaba un contaminante diferente. Sin embargo, el dataset global se encontraba en formato ancho, donde cada contaminante es una columna. Para poder integrar ambos datasets, fue necesario transformar el dataset de Colombia mediante una tabla pivot, convirtiendo los contaminantes en columnas. Esto permitió estandarizar la estructura de ambos datasets y facilitar la integración.

5.3. Carga (Load)

Se generaron tres archivos de salida:

- colombia_limpio.XLSX
- global_limpio.XLSX
- dataset_integrado_calidad_aire.XLSX

El dataset integrado contiene información de Colombia y del contexto global en una misma estructura de datos.

5.4. Descripción técnica del pipeline ETL

El pipeline ETL fue desarrollado en Python utilizando la librería pandas para el procesamiento de datos y la librería pathlib para la gestión de rutas y archivos.

El pipeline fue estructurado en funciones, donde cada función representa una etapa del proceso ETL:

Función	Etapa ETL	Descripción
get_paths()	Configuración	Define las rutas de entrada y salida
extract_data()	Extract	Carga los datasets desde archivos CSV
quality_report()	Data Quality	Genera un reporte de calidad de datos
transform_colombia()	Transform	Limpieza y pivot del dataset de Colombia
transform_global()	Transform	Limpieza y estandarización del dataset global
integrate_data()	Integración	Une los datasets en uno solo
final_report()	Validación	Genera reporte final del dataset
save_XLSX()	Load	Guarda los datasets procesados
main()	Pipeline	Ejecuta todo el proceso ETL

Tabla 3. Descripción pipeline ETL

5.5. Decisiones de transformación de datos

Durante la fase de transformación se tomaron varias decisiones técnicas para garantizar la calidad e integración de los datos:

- Se decidió trabajar con los contaminantes PM2.5, PM10, NO2, SO2, O3 y CO por ser los contaminantes más utilizados en estudios de calidad del aire.
- Se eliminaron registros con valores nulos en País y Ciudad, ya que estas variables son necesarias para realizar análisis comparativos.
- Se transformó el dataset de Colombia de formato largo a formato ancho para poder integrarlo con el dataset global.
- Se estandarizaron los nombres de las columnas para que ambos datasets tuvieran la misma estructura.
- Se integraron los datasets utilizando concatenación, ya que ambos datasets representan observaciones del mismo fenómeno, pero en diferentes contextos geográficos.

Estas decisiones permitieron generar un dataset integrado, limpio y estructurado para análisis posteriores.

5.6. Arquitectura del pipeline ETL

El pipeline ETL fue diseñado de forma modular, separando las etapas de extracción, validación de calidad, transformación, integración y carga. Esta arquitectura permite que el proceso sea reproducible, mantenible y escalable.

El pipeline inicia con la extracción de datos desde archivos CSV, seguido de un análisis de calidad de datos para identificar valores nulos, duplicados y tipos de datos incorrectos. Posteriormente, se realiza la transformación de cada dataset de forma independiente, generando datasets intermedios limpios. Finalmente, los datasets transformados se integran en un dataset consolidado que es almacenado como archivo final.

Esta estructura permite mantener trazabilidad de los datos desde la fuente original hasta el dataset final, lo cual es una buena práctica en proyectos de ingeniería de datos.

La integración de los datasets se realizó mediante concatenación y no mediante un join, ya que los datasets no representan la misma población de registros, sino observaciones de diferentes ciudades en diferentes contextos geográficos. Por lo tanto, la concatenación permite unificar los datos en un solo dataset manteniendo todas las observaciones.

La transformación mediante pivot corresponde a una transformación estructural de los datos, ya que cambia la forma en que los datos están organizados (de formato largo a formato ancho). Este tipo de transformación es común en procesos ETL cuando se requiere estandarizar la estructura de diferentes fuentes de datos para permitir su integración.

5.7. Diagrama del proceso de ETL

Figura 1: Diagrama del proceso de ETL

La Figura 1 muestra el flujo del proceso ETL desarrollado en el proyecto. El proceso inicia con la extracción de datos desde las fuentes de Colombia y datos globales. Posteriormente,

se realiza un análisis de calidad de datos, seguido de la transformación de cada dataset, la integración de las fuentes y finalmente la generación del dataset consolidado.

5.8. Diagrama de Arquitectura del Pipeline

Figura 2: Arquitectura del pipeline ETL

La Figura 2 presenta la arquitectura del pipeline ETL diseñada para el procesamiento de los datos de calidad del aire. La arquitectura se organiza en varias capas: fuentes de datos, extracción, calidad de datos, transformación, integración y carga. En la capa de fuentes se encuentran los datasets originales de Colombia y del contexto global.

En la etapa de extracción se realiza la lectura de archivos CSV mediante Python y pandas. Posteriormente, en la capa de calidad de datos se validan nulos, duplicados y tipos de datos. En la capa de transformación se ejecutan operaciones de limpieza, pivot, estandarización y selección de variables. Luego, en la capa de integración se unifican ambas fuentes en un dataset consolidado. Finalmente, en la capa de carga se genera el archivo XLSX final listo para análisis posteriores. Esta arquitectura evidencia un diseño modular, reproducible y escalable del pipeline ETL

5.9. Diagrama de flujo del proceso

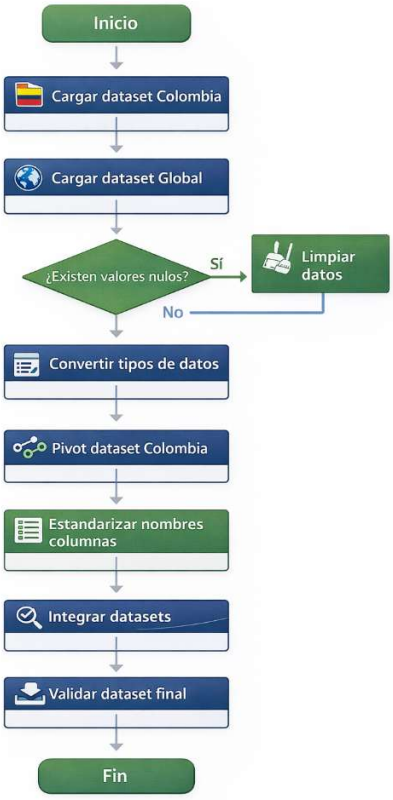

Figura 3: Diagrama de flujo del proceso ETL

La Figura 3 muestra la secuencia lógica del proceso ETL implementado en el proyecto. El flujo inicia con la carga de los datasets de Colombia y global. Luego se realiza una validación inicial de calidad de datos para identificar valores nulos y problemas de estructura. Si existen nulos, se ejecutan procesos de limpieza. Posteriormente, se convierten tipos de datos, se realiza el pivot del dataset de Colombia, se estandarizan los nombres de columnas y se integran los datasets. Finalmente, se valida el dataset final y se genera el archivo consolidado. Este diagrama permite comprender el orden y la dependencia entre las etapas del pipeline.

5.10. Reproducibilidad del Pipeline ETL

El pipeline ETL fue diseñado para ser reproducible, lo que significa que puede ejecutarse nuevamente en cualquier momento utilizando los mismos datos de entrada y generando los mismos resultados.

El proceso ETL se ejecuta mediante un script principal en Python (main.py), el cual organiza el pipeline en etapas modulares: extracción, validación de calidad, transformación, integración y carga. Cada etapa se implementa mediante funciones independientes, lo que facilita el mantenimiento y la escalabilidad del proceso.

El pipeline genera automáticamente los siguientes archivos de salida:

- colombia_limpio.XLSX
- global_limpio.XLSX
- dataset_integrado_calidad_aire.XLSX

Además, el script crea automáticamente las carpetas de salida si no existen, lo que permite ejecutar el proceso sin necesidad de configuraciones adicionales. Esta característica garantiza que el proceso ETL sea reproducible, automatizado y estructurado, siguiendo buenas prácticas de ingeniería de datos.

6. Validación de datos

Después del proceso de transformación e integración, se realizó una validación del dataset final, verificando:

- Dimensiones del dataset.
- Valores nulos.
- Columnas finales.
- Primeros registros del dataset.

El dataset final contiene variables como:

- Ciudad
- País
- Año
- PM2.5
- PM10
- NO2
- SO2
- O3
- CO
- AQI

Esto confirma que los datos fueron integrados correctamente y están listos para la fase de análisis.

6.1. Diccionario de datos

El dataset final contiene las siguientes variables:

Variable	Descripción
País	Nombre del País
Ciudad	Nombre de la ciudad
Año	Año de medición
PM2.5	Material particulado menor a 2.5 micras
PM10	Material particulado menor a 10 micras
NO2	Dióxido de nitrógeno
SO2	Dióxido de azufre
O3	Ozono
CO	Monóxido de carbono
AQI	Índice de calidad del aire

Tabla 1: Este diccionario de datos permite entender el significado de cada variable del dataset integrado.

La validación del dataset final es una etapa fundamental en los procesos ETL, ya que permite garantizar que los datos transformados cumplen con las condiciones de calidad necesarias antes de ser utilizados en análisis o modelos de ciencia de datos.

6.2. Reglas de validación de datos

Para garantizar la calidad del dataset final, se definieron reglas de validación de datos que permiten verificar la consistencia e integridad de la información después del proceso de transformación e integración.

Las principales reglas de validación implementadas fueron:

- No deben existir valores nulos en las variables **País** y **Ciudad**, ya que estas variables identifican la ubicación geográfica de las observaciones.
- La variable **Año** debe ser numérica y mayor que cero.
- Las variables de contaminantes (**PM2.5, PM10, NO2, SO2, O3, CO**) deben ser numéricas.
- Los valores de contaminantes no deben ser negativos.
- No deben existir registros duplicados para la misma combinación de **País – Ciudad – Año**.
- El dataset final debe contener la misma estructura de columnas para todas las observaciones.

Estas reglas permiten garantizar que el dataset integrado tenga condiciones mínimas de calidad para ser utilizado en análisis de datos, visualizaciones o modelos de ciencia de datos.

6.3. Linaje de datos

El linaje de datos describe el recorrido de los datos desde su fuente original hasta el dataset final generado por el proceso ETL. Este proceso permite mantener la trazabilidad de los datos y entender las transformaciones aplicadas en cada etapa.

Dataset	Fuente	Proceso aplicado	Dataset resultante
Calidad del aire Colombia	Datos Abiertos Colombia	Limpieza, conversión de tipos, filtrado de contaminantes, pivot	colombia_limpio.XLSX
Global Air Pollution	Kaggle	Eliminación de nulos, renombrado de columnas, selección de variables	global_limpio.XLSX
Integración	Colombia + Global	Concatenación y estandarización	dataset_integrado_calidad_aire.XLSX

Tabla 2. Linaje de datos

El linaje de datos permite garantizar la trazabilidad de la información y entender cómo los datos originales fueron transformados hasta generar el dataset final. Esta práctica es común en procesos de ingeniería de datos y asegura transparencia en el manejo de la información.

7. Resultado del proceso ETL

El resultado del proceso ETL es un dataset integrado que combina información de calidad del aire de Colombia y del contexto global. Este dataset permitirá realizar análisis comparativos, identificar ciudades con mayores niveles de contaminación y estudiar el comportamiento de los contaminantes a lo largo del tiempo.

Después de la integración, el dataset final quedó conformado por 24,133 registros y 10 columnas. Se verificó la estructura final y se analizaron los valores nulos por variable. Se observó que las columnas País y Ciudad no presentan valores nulos, lo cual garantiza consistencia geográfica mínima para el análisis. Algunas columnas como PM10, SO2 y AQI presentan valores faltantes, lo cual se explica porque no todas las variables están disponibles en ambas fuentes originales.

El dataset integrado permite analizar la calidad del aire desde una perspectiva comparativa entre Colombia y otras ciudades del mundo, lo cual abre la posibilidad de realizar análisis exploratorios, visualizaciones, modelos predictivos y estudios de comportamiento de contaminantes a lo largo del tiempo.

```
--- REPORTE FINAL DATASET INTEGRADO ---
Dimensiones: (24133, 10)

Valores nulos:
Ciudad        0
Año       23035
CO          975
NO2         821
O3          846
PM10      23128
PM2.5       509
SO2       23875
Pais          0
AQI        1098
dtype: int64

Primeras filas:
           Ciudad    Año  CO  NO2  O3  PM10  PM2.5  SO2      Pais  AQI
0  AGUSTIN CODAZZI  2,021 NaN  NaN NaN  22.7   11.1  NaN  COLOMBIA  NaN
1  AGUSTIN CODAZZI  2,022 NaN  NaN NaN  24.1   12.4  NaN  COLOMBIA  NaN
2  AGUSTIN CODAZZI  2,014 NaN  NaN NaN  25.9    9.7  NaN  COLOMBIA  NaN
3  AGUSTIN CODAZZI  2,015 NaN  NaN NaN  31.3   16.6  NaN  COLOMBIA  NaN
4  AGUSTIN CODAZZI  2,016 NaN  NaN NaN  26.2   16.1  NaN  COLOMBIA  NaN

✅ dataset_integrado_calidad_aire.xlsx guardado en:
C:\Users\jorge\OneDrive\Desktop\MAESTRIA\SEMESTRE 1\ETL\ProyectoETL\data\output\dataset_integrado_calidad_aire.xlsx

🎉 ETL finalizado correctamente.
PS C:\Users\jorge\AppData\Local\Programs\Microsoft VS Code>
```

Imagen 2. Evidencia del reporte final del dataset integrado.

Adicionalmente, es importante considerar que los datasets utilizados presentan diferencias significativas en su origen, metodología y nivel de agregación. El dataset global proviene de una agregación no oficial basada principalmente en datos urbanos y, en algunos casos, en índices transformados como el AQI. Por otro lado, el dataset de Colombia corresponde a mediciones oficiales del IDEAM, obtenidas a partir de estaciones de monitoreo físico y expresadas en concentraciones reales de contaminantes. Debido a estas diferencias, ambos conjuntos de datos no son directamente comparables sin un proceso riguroso de estandarización.

En este contexto, el análisis desarrollado se enfoca en la identificación de tendencias, patrones y comportamientos generales, en lugar de realizar comparaciones estrictas de valores absolutos. Este enfoque permite integrar ambas fuentes de información de manera coherente, reduciendo posibles sesgos derivados de las diferencias metodológicas.

7.1 Análisis de Resultados del Proceso de ETL mediante POWER BI

La fase de carga (Load) no solo implicó el almacenamiento del dataset final, sino también su integración en Power BI como herramienta de inteligencia de negocios, permitiendo la construcción de visualizaciones interactivas para el análisis exploratorio de datos (EDA). Esto facilitó la validación de los resultados del proceso ETL y la identificación de patrones, tendencias y anomalías en la calidad del aire.

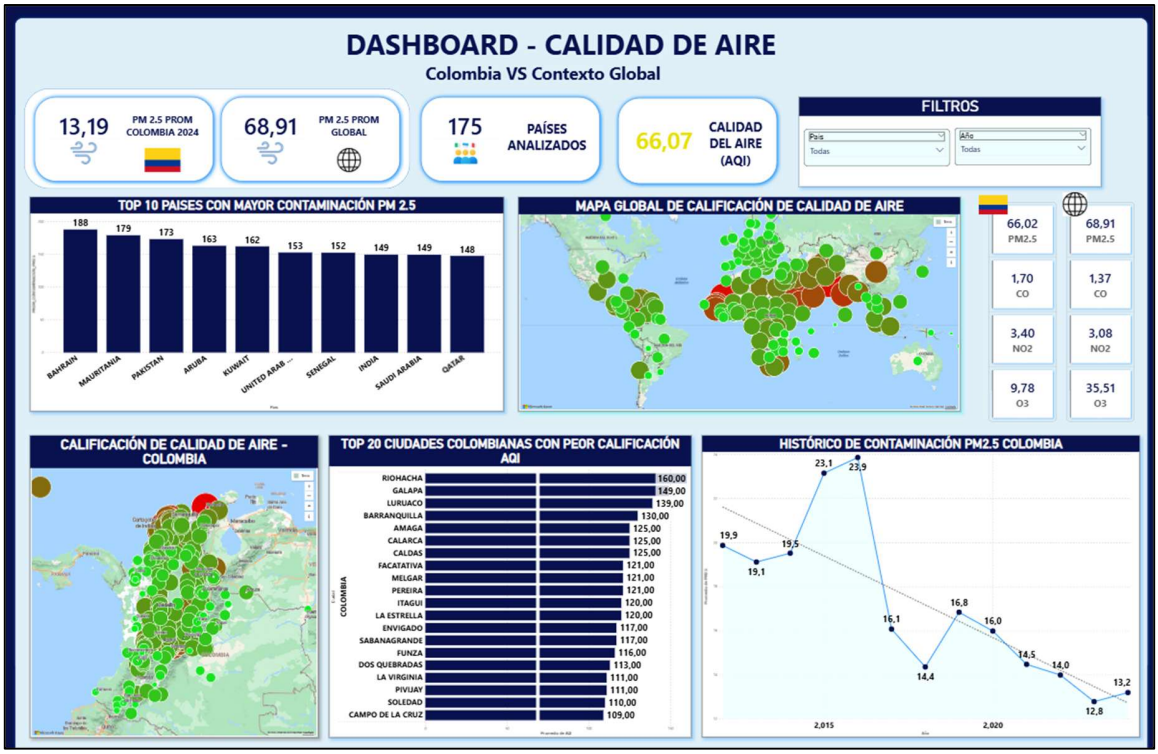

Imagen 3. Dashboard calidad del aire.

A partir del dashboard desarrollado en Power BI (Dashboard calidad del aire), se obtuvieron los siguientes hallazgos:

7.1.1 Comparación entre Colombia y el contexto global

El análisis comparativo evidencia que Colombia presenta un promedio de PM2.5 de 13,19 µg/m³, considerablemente inferior al promedio global estimado en aproximadamente 68,91 µg/m³. Esta diferencia sugiere que, en términos generales, la calidad del aire en Colombia es relativamente mejor que la observada en muchos otros países incluidos en el dataset.

No obstante, esta conclusión debe interpretarse con cautela. El promedio global puede estar influenciado por la inclusión de ciudades altamente contaminadas o por diferencias en la forma de medición (por ejemplo, uso de AQI vs concentraciones reales). Aun así, la brecha observada permite identificar una tendencia clara: Colombia no se encuentra dentro de los países con mayores niveles de contaminación por material particulado fino.

7.1.2 Identificación de países con mayor contaminación

El análisis de los países con mayores niveles de PM2.5 revela que naciones como Bahrain, Mauritania, Pakistán, Kuwait e India presentan valores extremadamente altos, en algunos

casos superiores a los 150 µg/m³. Estos niveles son considerablemente superiores a los límites recomendados por organismos internacionales como la OMS.

Este patrón sugiere una concentración geográfica de la contaminación en regiones específicas, particularmente en Medio Oriente y el sur de Asia. Factores como la alta industrialización, el uso intensivo de combustibles fósiles, las condiciones climáticas (baja dispersión de contaminantes) y la presencia de polvo desértico pueden explicar estos niveles elevados.

7.1.3 Distribución espacial de la contaminación a nivel global

El mapa global de calidad del aire permite visualizar la distribución espacial de los niveles de contaminación, evidenciando una alta concentración de zonas críticas en Asia, especialmente en países con rápido crecimiento industrial y urbano.

En contraste, regiones como América Latina presentan en su mayoría niveles moderados o relativamente bajos de contaminación. Colombia, en particular, se ubica dentro de este grupo, lo que coincide con los valores promedio observados.

7.1.4 Análisis de la calidad del aire en Colombia a nivel local

A nivel nacional, el análisis de las ciudades con peor calificación de calidad del aire (AQI) muestra que municipios como Riohacha, Galapa, Luruaco y Barranquilla presentan los valores más altos. Es notable que varias de estas ciudades se encuentran en la región Caribe.

Este comportamiento puede estar asociado a múltiples factores, como condiciones climáticas particulares (altas temperaturas, baja precipitación), presencia de material particulado proveniente de fuentes naturales (polvo), así como actividades industriales, portuarias o de transporte.

7.1.5 Tendencia temporal de la contaminación en Colombia

El análisis histórico de los niveles de PM2.5 en Colombia muestra una tendencia general decreciente a lo largo del tiempo. Se identifican algunos picos en años específicos (alrededor de 2015–2016), seguidos de una reducción progresiva hasta alcanzar valores cercanos a 12–13 µg/m³ en los años más recientes.

Esta tendencia podría estar asociada a la implementación de políticas ambientales más estrictas, mejoras tecnológicas en procesos industriales, renovación del parque automotor o incluso factores externos como variaciones climáticas.

8. Limitaciones del proyecto

El proyecto presenta diversas limitaciones que deben ser consideradas al momento de interpretar los resultados. En primer lugar, no todas las ciudades cuentan con información completa para todos los contaminantes, lo que genera heterogeneidad en el dataset y puede introducir sesgos en el análisis comparativo. Esta ausencia de datos afecta especialmente variables como PM10, SO_2 y algunos indicadores derivados, limitando la posibilidad de realizar análisis multivariados completos.

En segundo lugar, los datasets utilizados no poseen la misma estructura ni las mismas variables, lo que implicó la necesidad de realizar procesos de estandarización tanto a nivel estructural como semántico. Estas transformaciones, aunque necesarias para la integración, pueden introducir cierta pérdida de información o simplificación de los datos originales.
Adicionalmente, se identificaron valores faltantes en varias variables, los cuales fueron conservados para no alterar la naturaleza de los datos. Sin embargo, estos valores podrían ser tratados en futuros trabajos mediante técnicas de imputación estadística o modelos de machine learning, con el fin de mejorar la completitud del dataset.

Otra limitación importante radica en las diferencias metodológicas entre las fuentes de información. Mientras que el dataset de Colombia proviene de mediciones oficiales del IDEAM basadas en estaciones de monitoreo, el dataset global corresponde a una agregación de datos urbanos que puede incluir diferentes metodologías de captura, procesamiento y reporte (incluyendo el uso de índices como el AQI). Estas diferencias dificultan la comparabilidad directa de los valores.

Finalmente, el análisis se basa en datos históricos y agregados, lo que impide capturar dinámicas en tiempo real o eventos puntuales de contaminación. Asimismo, factores externos como condiciones meteorológicas, fenómenos naturales o políticas ambientales no fueron incorporados explícitamente en el modelo, lo cual podría enriquecer futuros análisis.

9. Conclusiones y Reflexiones Finales

El desarrollo del presente proyecto permitió diseñar e implementar un proceso ETL completo orientado a la integración de datos de calidad del aire provenientes de múltiples fuentes con diferentes estructuras y niveles de calidad. A lo largo del proceso, se identificaron y abordaron problemáticas comunes en proyectos de ingeniería de datos, como la presencia de valores faltantes, inconsistencias estructurales y falta de estandarización entre datasets.

Mediante las fases de extracción, transformación y carga, se logró consolidar un dataset integrado que combina información de Colombia y del contexto global, permitiendo su posterior análisis. La fase de transformación fue especialmente relevante, ya que incluyó procesos de limpieza, normalización, homogeneización de variables y alineación semántica, garantizando la coherencia del dataset final.

Asimismo, la fase de carga se complementó con el uso de herramientas de inteligencia de negocios como Power BI, lo que permitió realizar análisis exploratorios mediante dashboards interactivos. Esto facilitó la identificación de patrones, tendencias temporales, diferencias geográficas y comportamientos específicos de los contaminantes.

Los resultados obtenidos evidencian que Colombia presenta, en promedio, niveles de contaminación por PM2.5 inferiores al contexto global, aunque con variaciones importantes a nivel regional y diferencias en el comportamiento de contaminantes específicos como el ozono. Este tipo de hallazgos resalta la importancia de analizar la calidad del aire desde múltiples dimensiones, incluyendo variables geográficas, climáticas y socioeconómicas.

El pipeline ETL desarrollado se caracteriza por ser modular, reproducible y escalable, lo que permite su adaptación a nuevos datasets o problemáticas similares. Además, el dataset final generado constituye una base sólida para el desarrollo de análisis más avanzados, incluyendo modelos predictivos, análisis de series de tiempo y estudios de impacto ambiental.

En conclusión, el proyecto no solo cumple con el objetivo de integrar y analizar datos de calidad del aire, sino que también demuestra la importancia de aplicar buenas prácticas en ingeniería de datos para garantizar la calidad, confiabilidad y utilidad de la información en la toma de decisiones.